

ClinEnv: An Interactive Multi-Stage Long Horizon EHR Environment for Agents

Authors: Yuxing Lu, Yushuhong Lin, Wenqi Shi, J. Ben Tamo, Xukai Zhao, Jinzhuo Wang et al. • **Year:** 2026 • **arXiv:** 2606.02568 • PDF

 复制 BibTeX

 贡献

 技术细节

 知识关联

 复现指南

贡献与创新点

核心贡献: ClinEnv is the first interactive benchmark that evaluates LLMs as attending physicians managing real multi-stage hospitalizations with deterministic ontology-grounded scoring of decisions and measurement of information-gathering process quality.

新颖之处: It unifies real EHR trajectories, multi-stage sequential decisions, active information acquisition from specialized agents, and process-aware dual evaluation, all without manual annotation.

解决的问题: Existing benchmarks could not assess holistic clinical reasoning involving sequential decisions under uncertainty and active information seeking, obscuring the gap between diagnostic accuracy and management performance, and failing to measure information-acquisition efficiency.

原文出处

- [Abstract \(p.1\)](#): We present CLINENV, an interactive benchmark that evaluates LLMs as attending physicians over real inpatient admissions under a paradigm we term Longitudinal Inpatient Simulation. Each case is automatically constructed into an ordered sequence of decision stages; at every stage the model must actively query four specialized agents before committing to medications, procedures, and diagnoses. CLINENV scores both

what the model decides, through deterministic ontology-grounded matching, and how it gathers information.

- [Abstract \(p.1\)](#): Our contributions are: (i) An automated case construction pipeline that converts raw admissions into multi-stage cases without manual annotation; (ii) An interactive multi-agent clinical environment requiring active information acquisition before each decision; (iii) A dual evaluation framework covering decision accuracy and process quality.
- [Abstract \(p.1\)](#): CLINENV makes this information-acquisition gap, invisible to outcome-only evaluation, directly measurable.
- [Frontmatter \(p.1\)](#): None evaluates an LLM as an attending physician managing a real, multistage hospitalization with deterministic verification of its decisions.

技术细节解释

▼ 1. 自动案例构建：多阶段决策序列生成（时间锚定与阶段分割） high

流水线先从出院记录中提取所有主治医师决策，然后通过滑动窗口将每个决策锚定到 EHR 时间线上（公式 (1)）。锚定后，每两个锚点之间的窗口事件构成一个临床阶段的上文 C_k ，并与该阶段的决策集合 G_k 和可用信息源 A_k 组合为阶段 S_k 。这样设计是为了让模型在每个阶段面对的是一段连续的真实临床证据，而非一次性看到全部记录，从而模拟真实诊疗中序贯决策、逐步“解锁”信息的过程。

$$S_k = (C_k, G_k, A_k), quad C_k = [prev_{end} + 1, d_i - 1]$$

 **类比：**好比将一部电影按剧情转折点自动切分成多个片段，每个片段只给观众提供截至目前的情节，要求观众在看完片段后做出关键选择，然后才能播放下一段。

 出处：Section 3.2 (p.3)




Figure 1: Overview of CLINENV. Patients' admissions are preprocessed into event timelines, converted into multi-stage cases via a five-step pipeline, and evaluated in an interactive environment where the model queries specialized agents before committing decisions, scored on both process and outcome quality. (论文原图)

▼ 2. 药物评分：ATC 层次部分信用与动作类型硬门控 high


预测药物与真实药物通过匈牙利算法匹配，匹配时动作类型（开始/停止/切换/调整）必须一致，否则得分为零；动作一致时则按 ATC 编码的最长公共前缀长度给予部分分数（公式 (7)）。调整类药物还考虑方向（增加/减少）是否冲突（公式 (8)）。这种硬门控保证模型不只是选相似的药，还必须理解当前诊疗阶段该做什么药物操作；层次部分信用则让相似但非完全一致的药物仍能获得合理分数。

Misplaced &

💡 **类比：**评分如同评判一道菜的烹饪：调料必须匹配（糖/盐不能互换），但可以使用同一科（如芸香科）的柑橘替代，根据亲缘远近给不同的分；火候操作（大火爆炒 vs. 小火慢炖）错了则整个菜作废。

📍 出处：Section 5.1 (p.5)

ClinEnv Drug Scoring: ATC Hierarchical Partial Credit with Action-Type Hard Gate



教学示意图：药物评分：ATC 层次部分信用与动作类型硬门控

3. 诊断与手术评分：ICD 层次 F1 (HDF1) mid

模型提交的自由文本先被映射到 ICD 编码 $hatc$ ，与真实编码 c^* 各自扩展为包含所有祖先编码的集合 $hatA$ 和 A^* ，然后计算两集合的层次 F1（公式 (9)）。这样做的好处是即使模型预测了一个比真实诊断更泛或更具体的编码，若它们在树中靠近，仍能获得较高的分数，从而更细腻地反映临床语义的接近程度，而不是简单的是非判断。

$$textHDF1(hatc, c^*) = \frac{2|hatA \cap A^*|}{|hatA| + |A^*|}$$

💡 **类比：**好比家族谱匹配：不仅看这个人是不是同一个人，还要看他的直系长辈（祖先）是否吻合。如果只是堂兄弟关系，重合的祖先少，分数就低；如果是亲兄弟，祖先完全相同，分数就高。

📌 出处：Section 5.1 (p.5)


ICD Hierarchical F1 (HDF1) for Diagnosis & Procedure Scoring

$$HDF1(c^*) = \frac{2 |\tilde{I} \cap A^*|}{|\tilde{I}| + |A^*|}$$


Step 1: Expand to Ancestor Sets

Ground truth code: $c^* = J45.0$ (Asthma)
 Ancestor set $A^* = \{ J45.0, J45, J40-J47, J00-J99, \dots \}$
 Predicted code: $\hat{h} = J44.9$ (COPD, unspecified)
 Ancestor set $\tilde{I} = \{ J44.9, J44, J40-J47, J00-J99, \dots \}$
Intersection: $\tilde{I} \cap A^* = \{ J40-J47, J00-J99, \dots \}$

ICD-10 Hierarchy (Partial)



Step 2: Compute HDF1 via Set Overlap



教学示意图：诊断与手术评分：ICD 层次 F1 (HDF1)

4. 信息获取效率度量：冗余查询惩罚 mid

每个阶段模型可以调用多个信息代理，效率得分定义为覆盖率除以 $\max(1, K/|A_k|)$ ，其中 K 是总查询次数， $|A_k|$ 是激活的代理数量（公式 (12)）。若查询次数 K 不超过代理数，则不惩罚；超过时效率线性下降。这让模型不仅要问得全面，还要问得简洁，防止反复提出冗余问题，从而度量其信息获取的策略水平。

$$texteff = \frac{textcov}{\max(1, K/|A_k|)}$$

💡 类比：好比去图书馆查资料，每个书架（信息源）都有固定内容，如果你在一两个书架上反复拿书却不看别的，管理员会认为效率低下；只有每个书架借一本并快速找到所需信息，才算高效。

📌 出处：Section 5.2 (p.6)


5. 诊断可接地性扫描：滑动窗口验证 ICD 证据 mid

对所有事件时间线 T 使用重叠滑动窗口（公式 (2)）扫描，仅当某个出院 ICD 编码在至少一个窗口内被记录的操作或处置所支持时，才纳入最终诊断阶段的地面真值。这剔除了那些虽在出院记录中出现但从未在住院过程中被管理或检查过的“名义”诊断，从而确保评估的诊断都是有实际临床行动支撑的。

$$W_i = [iS, \min(iS + W, T)], \text{quadi} = 0, 1, \dots, \lfloor \frac{T - WS}{S} \rfloor$$

💡 **类比：**类似于用放大镜逐段检查录像，只把那些在画面中出现过的演员名字列入最终字幕，有些片尾名单上的人其实从未出场，就被过滤掉了。

📍 出处：Section 3.2 (p.4)



教学示意图：诊断可接地性扫描：滑动窗口验证 ICD 证据


▸ 6. 实验室检查浪费比：基于 CMS 费用表的过度检查度量 low

模型在交互中每开一项检验，系统会通过嵌入检索和 LLM 重排序将其映射到 CMS 临床实验室收费表的一个条目，得到费用 $fee(t)$ 。若该项检查在真实临床过程中并无对应记录（即不必要的检查），则计入浪费开销 T_{excess} ，总浪费比 r_{waste} 就是浪费开销占总开销的比例（公式 (13)）。这激励模型避免开具与当前临床决策无关的检验，从而模拟真实世界中控制医疗成本的需求。

$$r_{waste} = \frac{sum_{t \in T_{excess}} fee(t)}{sum_{t \in T_{ordered}} fee(t)}$$

💡 **类比：**如同自助餐计费：吃掉的菜肴正常付款，但拿上桌却一口没动的菜要额外按浪费比例加收费用，鼓励拿多少吃多少。

📍 出处：Section 5.2 (p.6)



教学示意图：实验室检查浪费比：基于 CMS 费用表的过度检查度量

🔗 知识关联

概念	相关论文	关系
Multi-agent interactive clinical environment	Schmidgall et al. 2024 (AgentClinic)	改进：ClinEnv 沿用多智能体交互范式，但用真实 EHR 轨迹取代了 LLM 模拟的患者和短病历片段，并用本体确定性匹配取代 LLM-as-judge 评分。
Evaluation frameworks for coding agents	Chen et al. 2021 (HumanEval)	借鉴：ClinEnv 受 HumanEval 及 SWEbench 等可执行环境推动编程智能发展的启发，将医学评估从静态选择题向可执行交互环境迁移。

概念	相关论文	关系
Deterministic ontology-grounded scoring	Kuhn 1955 (Hungarian algorithm)	继承：ClinEnv 使用匈牙利算法实现预测决策与真实决策的确定性最优匹配，并在此基础上引入 ATC 层级部分信用和 ICD 层次 F1，提升评分的领域适配性。
ATC hierarchy partial credit for drug matching	Chen et al. 2012 (ATC classification)	继承：ClinEnv 采用基于 ATC 解剖治疗化学分类系统的层级部分信用评分作为药物决策的软匹配度量，并依据实际用药行为附加动作方向约束。
Static medical knowledge benchmarks	Singhal et al. 2023 (MultiMedQA)	对比：MultiMedQA 等静态基准仅测量事实回忆，ClinEnv 弥补了缺少多阶段决策、主动信息获取和不确定下序贯承诺的不足。
EHR data-interaction benchmarks	Lee et al. 2022 (EHRSQL)	对比：EHRSQL 类基准测试原子式数据访问能力，而 ClinEnv 要求模型自行决定所需信息并主动查询多源异构临床环境，将评估重心从执行效率移至临床推理质量。

 复现指南

性能基准

设置	Baseline	结果	加速	显存
GPT-5.4 (overall)	-	decision F1 = 0.31	-	-
GPT-5.4 (diagnosis vs. management)	-	diagnosis F1 = 0.51, management F1 = 0.17	-	-

数据集

- **MIMIC-IV v3.1** — Structured EHR tables for timeline construction
- **MIMIC-IV-Note v2.2** — Clinical notes (discharge summaries, radiology reports)

- **CLINENV Benchmark** — Pre-processed multi-stage cases and evaluation environment

Generated by [PaperMind](#).